PHÂN LOẠI ĐỐI TƯỢNG THAM GIA GIAO THÔNG SỬ DỤNG RETINANET VÀ DEFORMABLE DETR: CÂN BẰNG VÀ MẤT CÂN BẰNG DỮ LIỆU

Lê Nguyễn Thành Tài[1],Nguyễn Đức Trọng[2],Võ Lê Toàn Thắng[3]

[1] Khoa Công nghệ Thông tin, Trường Đại học Sư phạm kỹ thuật Vĩnh Long
[2] Khoa Công nghệ Thông tin, Trường Đại học Sư phạm kỹ thuật Vĩnh Long
[3] Khoa Công nghệ Thông tin, Trường Đại học Sư phạm kỹ thuật Vĩnh Long

22022001@st.vlute.edu.vn, 22022012@st.vlute.edu.vn, 220220014@st.vlute.edu.vn

Tóm tắt — *Phát hiện và phân loại các đối tượng tham gia giao thông đóng vai trò quan trọng trong việc xây dựng các hệ thống hỗ trợ giám sát thông minh, an toàn giao thông và xe tự hành. Tuy nhiên, việc huấn luyện mô hình nhận dạng trong môi trường thực tế gặp nhiều thách thức do dữ liệu bị mất cân bằng, khiến mô hình có xu hướng học lệch về các lớp phổ biến. Trong bài báo này, chúng tôi đề xuất sử dụng kiến trúc Deformable DETR nhằm phát hiện và phân loại các đối tượng tham gia giao thông như biển báo, người đi bộ, xe máy, ô tô, xe tải, xe đạp và ổ gà. Bộ dữ liệu được xây dựng bằng cách gộp bốn tập dữ liệu công khai (Intersection-Flow-5K, Object Detection of 35 classes, Vietnamese Traffic Sign Detection, Road Issues Detection) với tổng cộng 24372 ảnh và 453982 đối tượng. Chúng tôi thực hiện tăng cường dữ liệu (data augmentation) cho các lớp hiếm và phân tích ảnh hưởng của cân bằng và mất cân bằng dữ liệu đến hiệu quả huấn luyện mô hình. Kết quả kỳ vọng cho thấy Deformable DETR có khả năng phát hiện các đối tượng nhỏ, phức tạp và bị che khuất tốt hơn các mô hình truyền thống, đồng thời việc xử lý mất cân bằng giúp tăng độ chính xác nhận diện ở các lớp hiếm.*

Từ khóa — *Deformable DETR, RetinaNet, Mất cân bằng dữ liệu, Nhận dạng đối tượng, Học sâu*

Keywords — *Deformable DETR, RetinaNet, Data imbalance, Object detection, Deep learning*

I. GIỚI THIỆU

A. Giới thiệu bài toán

An toàn giao thông đường bộ là một trong những thách thức lớn nhất tại Việt Nam, phản ánh trực tiếp qua các số liệu thống kê đáng báo động. Theo Ủy ban An toàn Giao thông Quốc gia, năm 2023, toàn quốc xảy ra 22.067 vụ tai nạn giao thông, khiến 11.628 người thiệt mạng và 15.292 người bị thương [1]. Tình hình tiếp tục diễn biến phức tạp trong năm 2024 với 21.532 vụ tai nạn, 9.954 ca tử vong và 16.044 người bị thương [2]. Chỉ trong 6 tháng đầu năm 2025, đã có 9.340 vụ tai nạn, dẫn tới 5.203 người chết và 6.256 người bị thương [3]. Những con số này nhấn mạnh tính cấp thiết của việc áp dụng các giải pháp công nghệ tiên tiến để giám sát và giảm thiểu tai nạn. Trong bối cảnh đó, các Hệ thống Giao thông Thông minh (ITS) sử dụng camera giám sát đang trở thành công cụ chủ chốt. Nhiệm vụ cốt lõi của các hệ thống này là phát hiện và phân loại chính xác các đối tượng tham gia giao thông, từ phương tiện phổ biến (xe máy, ô tô) đến các yếu tố rủi ro cao (người đi bộ, xe đạp, biển báo, và các chướng ngại vật như ổ gà). Tuy nhiên, việc phát hiện chính xác các đối tượng này trong thực tế phải đối mặt với nhiều thách thức. Các mô hình học sâu thường gặp khó khăn do điều kiện ánh sáng thay đổi, vật thể bị che khuất, và đặc biệt là sự mất cân bằng dữ liệu (data imbalance). Hiện tượng này xảy ra khi các lớp hiếm nhưng quan trọng về an toàn (như "ổ gà" hay "biển báo") có số lượng mẫu huấn luyện quá ít so với các lớp phổ biến (như "xe hơi"). Sự sụt giảm hiệu năng phát hiện các lớp hiếm do thiên lệch (bias) là một hạn chế cố hữu của các phương pháp hiện tại. Do đó, việc xây dựng một hệ thống có khả năng phát hiện đối tượng chính xác, đồng thời vượt qua được rào cản mất cân bằng dữ liệu, là vô cùng cần thiết. Trọng tâm của hệ thống này là cải thiện khả năng nhận diện các đối tượng hiếm, vốn có ý nghĩa quyết định đến an toàn giao thông.

B. Những nghiên cứu liên quan

Trong những năm gần đây, lĩnh vực phát hiện và phân loại đối tượng giao thông đã có nhiều bước tiến đáng kể nhờ sự phát triển của các mô hình học sâu, đặc biệt trong bối cảnh dữ liệu huấn luyện thường bị mất cân bằng. Tsung-Yi Lin và cộng sự (2017) giới thiệu RetinaNet với hàm mất mát Focal Loss, giúp giảm ảnh hưởng của các mẫu dễ và tập trung hơn vào các mẫu khó, từ đó khắc phục tình trạng chênh lệch giữa vùng nền và vùng chứa đối tượng. Mô hình đạt AP = 39,1% trên COCO test-dev, vượt qua Faster R-CNN (36,2%) và trở thành cột mốc quan trọng trong hướng phát hiện một giai đoạn [4]. Tiếp đó, Xinlong Zhu và cộng sự (2021) đề xuất Deformable DETR, kết hợp cơ chế deformable attention và multi-scale feature map, giúp mô hình hội tụ nhanh hơn gấp 10 lần và đạt AP = 46,9%, cải thiện rõ rệt khả năng phát hiện vật thể nhỏ trong cảnh giao thông phức tạp [5]. Ở một hướng tiếp cận khác, Jian Pang và cộng sự (2019) phát triển Libra R-CNN, một kiến trúc cân bằng dữ liệu ở nhiều cấp độ (mẫu, đặc trưng, mục tiêu), giúp tăng AP trung bình thêm 2,5 điểm so với các mô hình hai giai đoạn truyền thống [6]. Tổng quan của Kaan Oksuz và cộng sự (2020) về vấn đề mất cân bằng trong phát hiện đối tượng đã chỉ ra rằng các kỹ thuật như loss re-weighting, focal sampling và augmentation theo lớp có thể nâng hiệu năng 5–7% mAP, tùy cấu trúc nền [7]. Bên cạnh đó, các phương pháp tăng cường dữ liệu đóng vai trò quan trọng trong việc mở rộng tính đa dạng của mẫu huấn luyện. Sanghyun Yun và cộng sự (2019) đề xuất CutMix, cho phép trộn vùng ảnh và nhãn giữa hai mẫu, giúp mô hình học đặc trưng bền vững hơn và tăng độ chính xác thêm 2–3% [8], trong khi Alexey Bochkovskiy (2020) áp dụng Mosaic Augmentation trong YOLOv4, giúp phát hiện tốt hơn đối tượng nhỏ và nâng mAP thêm 2,7% [9]. Trên ứng dụng thực tế, José Fernández và cộng sự (2021) triển khai hệ thống giám sát giao thông thời gian thực kết hợp augmentation và oversampling, đạt mAP = 92,4% và cải thiện rõ rệt hiệu quả nhận dạng ở các lớp hiếm như người đi bộ và xe buýt [10]. Tiếp đó, Shuai Liu và cộng sự (2022)

tinh chỉnh RetinaNet cho nhận dạng biển báo nhỏ, kết hợp multi-scale feature fusion với brightness augmentation, giúp tăng AP của lớp biển báo thêm 11,6% so với baseline [11]. Bộ dữ liệu UA-DETRAC của Liu Wen và cộng sự (2018), gồm hơn 140 000 khung hình và 1,2 triệu đối tượng gán nhãn, cung cấp nền tảng đánh giá chuẩn cho các mô hình phát hiện phương tiện trong điều kiện giao thông thực, đặc biệt hữu ích cho nghiên cứu về dữ liệu mất cân bằng [12]. Cuối cùng, Yuxin Fang và cộng sự (2021) giới thiệu YOLOS – một biến thể Transformer cho phát hiện đối tượng, đạt AP = 42,0% trên COCO và cho thấy khả năng học toàn cục hiệu quả trong cảnh giao thông đa vật thể [13].

II. CÁC CÔNG VIỆC LIÊN QUAN

A. Đặc điểm của đối tượng giao thông

Hệ thống giao thông đường bộ bao gồm nhiều loại đối tượng khác nhau như phương tiện cơ giới, người đi bộ, các loại biển báo, đèn tín hiệu, vật cản và các yếu tố hạ tầng như ổ gà hay vạch kẻ đường. Việc nhận dạng và phân loại chính xác các đối tượng này đóng vai trò quan trọng trong các ứng dụng giám sát giao thông thông minh, hỗ trợ xe tự hành và cảnh báo nguy hiểm. Tuy nhiên, các đối tượng giao thông có đặc điểm rất đa dạng về kích thước, hình dạng, màu sắc và điều kiện xuất hiện. Người đi bộ, xe đạp và xe máy có kích thước nhỏ, thường bị che khuất hoặc chồng lấn trong ảnh. Các đối tượng như biển báo, đèn tín hiệu lại chịu ảnh hưởng mạnh của ánh sáng và góc nhìn. Ngoài ra, sự xuất hiện không đồng đều giữa các lớp đối tượng trong dữ liệu (ví dụ: xe máy xuất hiện nhiều hơn xe tải, biển báo hay ổ gà) dẫn đến hiện tượng mất cân bằng dữ liệu, gây khó khăn cho quá trình huấn luyện mô hình học sâu. Do đó, việc thu thập, chuẩn hóa và tăng cường dữ liệu là bước tiền đề quan trọng để đảm bảo chất lượng huấn luyện mô hình phát hiện đối tượng giao thông.

B. Các mô hình được sử dụng trong nhận dạng đối tượng giao thông

1. RetinaNet

RetinaNet [4] là một mô hình phát hiện đối tượng một tầng (one-stage) nổi bật, được giới thiệu bởi Facebook AI Research Mục tiêu chính của RetinaNet là giải quyết một trong những thách thức lớn nhất của các mô hình one-stage: sự mất cân bằng cực đoan giữa các mẫu nền (background) và các mẫu đối tượng (foreground) trong quá trình huấn luyện. Để làm được điều này, mô hình đã giới thiệu một hàm mất mát mới là Focal Loss. Hàm mất mát này giúp giảm trọng số của các mẫu nền (là các mẫu dễ phân loại) và tập trung quá trình học vào các mẫu đối tượng khó. Điều này giúp tăng tốc độ hội tụ và cải thiện độ chính xác chung. Ngoài ra, RetinaNet sử dụng kiến trúc Mạng Kim tự tháp Đặc trưng (FPN), cho phép mô hình phát hiện hiệu quả các đối tượng ở nhiều kích thước khác nhau.

2. Deformable DETR

Deformable DETR [5] là một trong những kiến trúc phát hiện đối tượng dựa trên Transformer tiên tiến, được sử dụng rộng rãi để giải quyết các bài toán thị giác máy tính phức tạp. Mô hình này được thiết kế để khắc phục các hạn chế lớn của DETR [Ref] ban đầu, vốn có độ phức tạp tính toán cao và tốc độ hội tụ rất chậm. Cốt lõi của Deformable DETR là cơ chế Chú ý biến dạng (Deformable Attention), cho phép mô hình tối ưu hóa hiệu quả tính toán bằng cách chỉ tập trung vào một tập hợp nhỏ các điểm lấy mẫu thưa thớt (sparse) thay vì toàn bộ bản đồ đặc trưng. Điều này giúp giảm đáng kể độ phức tạp và tăng tốc độ hội tụ (nhanh hơn tới 10 lần), rút ngắn thời gian đào tạo mạng. Ngoài ra, Deformable DETR có khả năng xử lý hiệu quả các đặc trưng đa tỷ lệ, giúp cải thiện vượt trội khả năng phát hiện các đối tượng nhỏ.

3. Độ đo đánh giá mô hình

Hiệu quả của các mô hình phát hiện đối tượng được đánh giá dựa trên các độ đo chuẩn trong lĩnh vực thị giác máy tính, bao gồm Precision, Recall, F1-score [14] và Mean Average Precision (mAP) [15]. Các độ đo này phản ánh mức độ chính xác và khả năng bao phủ của mô hình trong quá trình phát hiện và phân loại đối tượng. Trong đó, Precision thể hiện tỉ lệ các dự đoán đúng trong tổng số dự đoán, được xác định theo công thức (1). Recall phản ánh khả năng phát hiện đầy đủ các đối tượng thực tế, được tính theo công thức (2). Để cân bằng giữa hai yếu tố này, F1-score được sử dụng, là trung bình điều hòa giữa Precision và Recall, được biểu diễn trong công thức (3). Cuối cùng, mAP thể hiện độ chính xác trung bình của mô hình trên toàn bộ các lớp đối tượng ở nhiều ngưỡng giao nhau (IoU) khác nhau [16], là độ đo tổng hợp quan trọng nhất dùng để so sánh hiệu năng giữa các mô hình RetinaNet và Deformable DETR.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (1) \qquad \text{Recall} = \frac{TP}{TP + FN} \quad (2) \qquad \text{F1} = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3)$$

Trong đó, TP (True Positive) là số đối tượng được mô hình phát hiện đúng, FP (False Positive) là số dự đoán sai (phát hiện nhầm), và FN (False Negative) là số đối tượng bị bỏ sót.

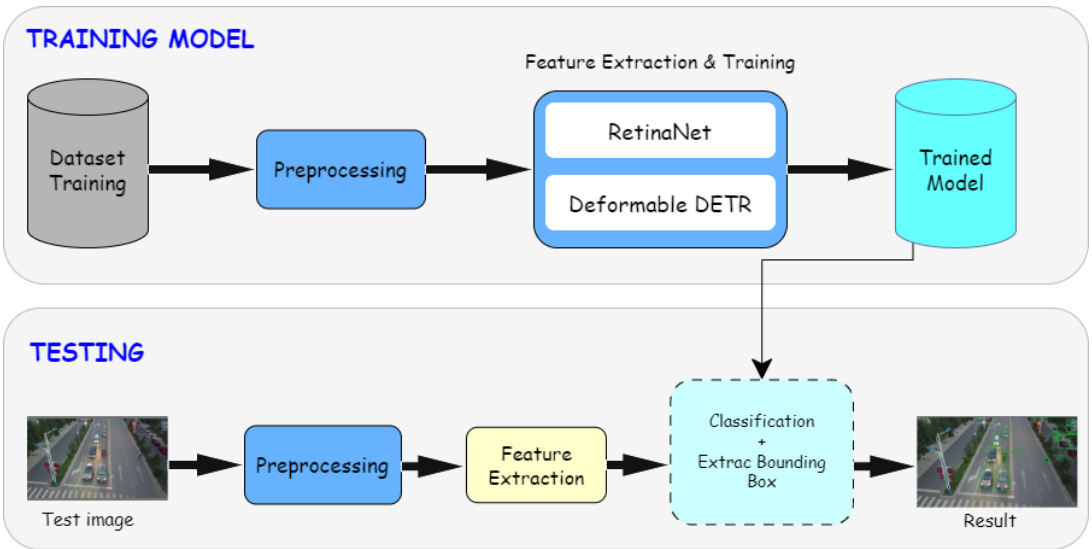
Chỉ số mAP (Mean Average Precision) được tính bằng trung bình cộng của các giá trị Average Precision (AP) trên toàn bộ các lớp, thể hiện khả năng tổng quát hóa của mô hình trên toàn bộ tập dữ liệu kiểm thử. Các giá trị Precision, Recall, F1-score và mAP được sử dụng xuyên suốt trong quá trình huấn luyện và kiểm thử để theo dõi độ hội tụ, độ ổn định và hiệu năng tổng thể của từng mô hình.

C. Phương pháp tăng cường và cân bằng dữ liệu trong đề tài

Bộ dữ liệu ban đầu được tổng hợp từ bốn nguồn công khai (Intersection-Flow-5K, Object Detection of 35 Classes, Vietnamese Traffic Sign Detection Augmentation, và Road Issues Detection Dataset), chuẩn hóa về định dạng YOLO, bao gồm 22.192 ảnh với 335.239 instances thuộc 11 lớp. Phân tích cho thấy mất cân bằng nghiêm trọng: Vehicle chiếm 64,7% trong khi Traffic Light (0,2%), Engine (0,4%), và Tricycle (0,6%) chiếm dưới 1% tổng instances. Để giải quyết vấn đề này, nghiên cứu áp dụng pipeline đa tầng kết hợp ba chiến lược: (1) Adaptive Undersampling giảm các lớp đa số theo tỷ lệ khác nhau (Vehicle 92%, Obstacle 70%, Bicycle 35%, Person 25%); (2) Repeat-Factor Sampling (RFS) với ngưỡng 1,5% nhân bản ảnh chứa lớp hiếm theo $r_c = \max(1, \sqrt{t/f_c})$ [17]; (3) Class-Specific Augmentation với hệ số riêng biệt (Tricycle 6,0×, Traffic Light 4,5×, Engine 3,5×, Vehicle 0,08×). Pipeline sử dụng Albumentations [18] với các phép biến đổi: RandomScale (±10%), HorizontalFlip (p=0,5), Affine Shear (±5°/±3°), Perspective (3-7%), RandomBrightnessContrast (±20%), MotionBlur. Mosaic Augmentation[18] theo YOLOv4/v5 [9] kết hợp 4 ảnh thành 800×800 với validation 3 tầng (min_visibility=25%, bbox capping), tạo 1000 biến thể ưu tiên lớp hiếm, mỗi ảnh tối đa 5 lần. Toàn bộ ảnh được chuẩn hóa 800×800 pixels. Kết quả: bộ dữ liệu mở rộng lên ~31.000 ảnh với phân bố cân bằng, tỷ lệ giữa lớp đa số/thiểu số cải thiện đáng kể.

III. PHƯƠNG PHÁP ĐỀ XUẤT

Trong nghiên cứu này, chúng tôi đề xuất phương pháp phát hiện và phân loại đối tượng giao thông dựa trên RetinaNet [4] và Deformable DETR [5], kết hợp kỹ thuật học sâu và cân bằng dữ liệu để cải thiện hiệu quả nhận dạng. Mô hình gồm hai giai đoạn: huấn luyện và kiểm thử, được trình bày chi tiết trong hình 2.



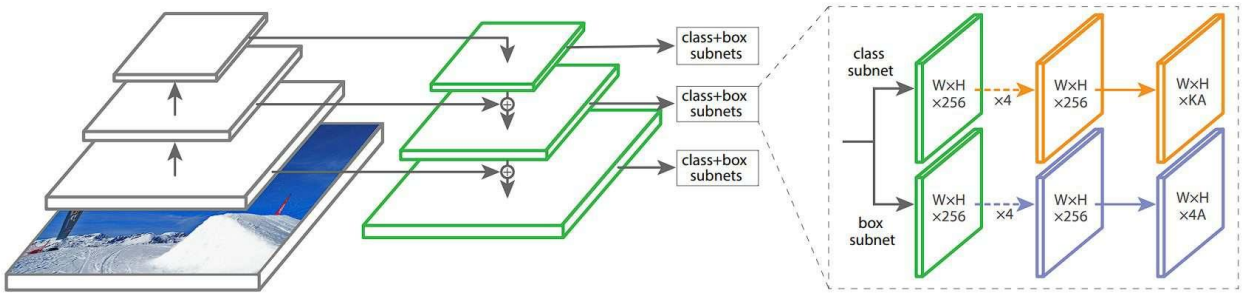
Hình 2. Mô hình đề xuất phân loại đối tượng tham gia giao thông

Kiến trúc mô hình RetinaNet và Deformable DETR

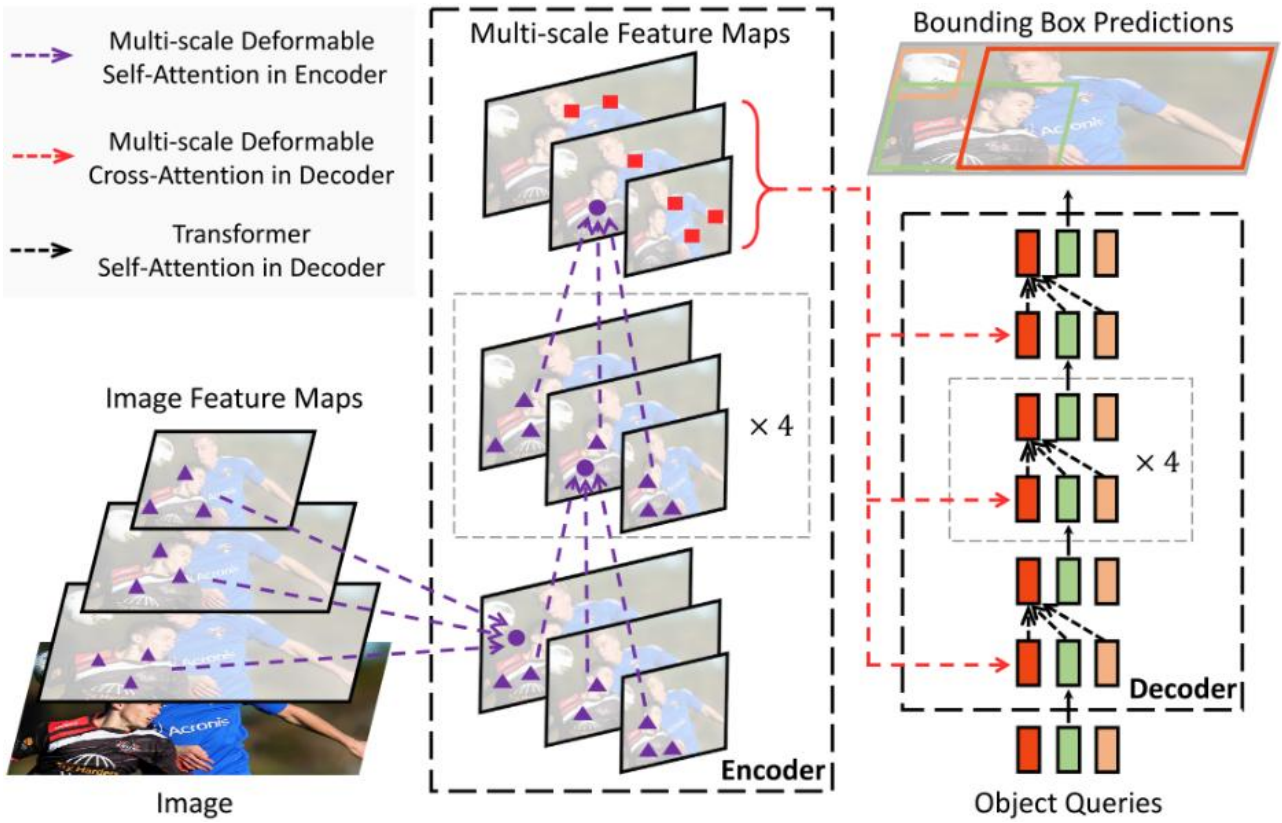
Nghiên cứu này, hai mô hình học sâu được sử dụng cho bài toán phát hiện đối tượng giao thông là RetinaNet và Deformable DETR.

Hình 3 minh họa cấu trúc của RetinaNet [4], trong đó backbone kết hợp với Feature Pyramid Network (FPN) để tạo đặc trưng ở nhiều mức tỉ lệ. Các tầng đặc trưng sau đó được đưa qua hai nhánh song song: classification subnet để dự đoán nhãn đối tượng và box subnet để dự đoán vị trí hộp giới hạn.

Hình 4 thể hiện kiến trúc của Deformable DETR [5] với hai thành phần chính là encoder và decoder. Encoder sử dụng Deformable Multi-Head Self-Attention để tập trung vào các vùng quan trọng trên đặc trưng ảnh đa tỉ lệ, trong khi decoder sử dụng cross-attention để kết hợp các truy vấn đối tượng (object queries) và tạo ra dự đoán hộp giới hạn cuối cùng.



Hình 3. Kiến trúc mô hình RetinaNet



Hình 4. Kiến trúc mô hình Deformable DETR

A. Pha huấn luyện

1. Tiền xử lý và chuẩn bị dữ liệu

Sau khi xử lý mất cân bằng lớp, bộ dữ liệu được chuyển đổi sang định dạng COCO [18] và phân chia theo tỷ lệ 70:15:15 cho các tập huấn luyện (Train), xác thực (Validation) và kiểm tra (Test). Để tăng cường khả năng tổng quát hóa và cải thiện hiệu năng phát hiện đối tượng đa tỷ lệ, chúng tôi áp dụng chiến lược huấn luyện đa kích thước (Multi-Scale Training) [19]. Cụ thể, đối với RetinaNet-ResNet50, kích thước ảnh đầu vào được lấy mẫu ngẫu nhiên từ tập {384, 432, 480} pixel, trong khi RetinaNet-MobileNetV3 sử dụng tập {416, 448, 480} pixel. Deformable DETR-ResNet50 được huấn luyện với kích thước cố định 480×480 pixel do kiến trúc Transformer yêu cầu độ ổn định về kích thước đầu vào. Chiến lược này đặc biệt hiệu quả trong việc cải thiện khả năng phát hiện các đối tượng nhỏ, chiếm 30% tổng số mẫu trong bộ dữ liệu. Quy trình tăng cường dữ liệu (data augmentation) được thiết kế nhằm cân bằng giữa tính đa dạng và tính ổn định của mô hình. Đối với RetinaNet, chúng tôi áp dụng các phép biến đổi sau: lật ngang ngẫu nhiên (HorizontalFlip, p=0.5) để mô hình bất biến với hướng di chuyển; điều chỉnh độ sáng-tương phản (RandomBrightnessContrast, p=0.2) mô phỏng các điều kiện ánh sáng thực tế; làm mờ Gaussian (Blur, blur_limit=3, p=0.1) để tăng tính robust với chất lượng ảnh thấp; và biến đổi không gian màu HSV (HueSaturationValue: hue_shift_limit=10, sat_shift_limit=15, val_shift_limit=10, p=0.3) để mô phỏng sự thay đổi màu sắc do điều kiện thời tiết và camera. Đối với Deformable DETR, chúng tôi thay thế HueSaturationValue bằng ColorJitter (p=0.3) để điều chỉnh đồng thời 4 tham số màu (brightness, contrast, saturation, hue), phù hợp hơn với đặc tính học biểu diễn của kiến trúc

Transformer. Tất cả các ảnh sau đó được chuẩn hóa theo thống kê ImageNet (mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]) để tương thích với các backbone được pre-train.

2. Rút trích đặc trưng và huấn luyện

Chúng tôi triển khai song song hai kiến trúc: RetinaNet (one-stage detector) và Deformable DETR (DETR-based detector) để so sánh hiệu năng trên bài toán phát hiện đối tượng giao thông đa tỷ lệ. RetinaNet-ResNet50: Mô hình sử dụng Feature Pyramid Network (FPN) kết hợp backbone ResNet-50 pre-trained trên ImageNet, tạo kim tự tháp đặc trưng đa tỷ lệ để phát hiện các đối tượng từ nhỏ đến lớn. Focal Loss (α=0.25, γ=2.0) được áp dụng để xử lý mất cân bằng lớp. Huấn luyện đa kích thước (Multi-Scale Training) với các độ phân giải {384, 432, 480} pixel được thay đổi ngẫu nhiên mỗi 200 batch. Tối ưu hóa bằng AdamW với learning rate 1×10^{-4}, weight decay 1×10^{-4}, gradient clipping 1.0, và OneCycleLR scheduler. Huấn luyện 50 epoch với batch size 8 và gradient accumulation 2 steps (effective batch size 16). RetinaNet-MobileNetV3: Sử dụng kiến trúc tương tự nhưng thay backbone bằng MobileNetV3-Large để tối ưu tốc độ suy luận. Huấn luyện đa kích thước với {416, 448, 480} pixel, learning rate cao hơn (3×10^{-4}) phù hợp với lightweight backbone. Áp dụng Exponential Moving Average (EMA, decay=0.9999) để ổn định quá trình học. Cấu hình khác tương tự RetinaNet-ResNet50. Deformable DETR-ResNet50: Sử dụng Deformable Multi-Head Attention để giảm complexity từ O(H×W) xuống O(K) bằng cách chỉ tập trung vào các điểm lấy mẫu quan trọng. Kích thước cố định 480×480 pixel do yêu cầu của kiến trúc Transformer. Backbone ResNet-50 được fine-tune với learning rate 1×10^{-5}, trong khi các module Transformer sử dụng 1×10^{-4}. Set Prediction Loss kết hợp L1, GIoU, và Focal Loss với Hungarian Matching. Optimizer AdamW, gradient clipping (max_norm=0.1), CosineAnnealingLR scheduler, batch size 4 với gradient accumulation 4 steps, huấn luyện 50 epoch.

B. Pha kiểm thử

Sau khi hoàn tất huấn luyện, các mô hình được kiểm thử trên tập dữ liệu kiểm thử không trùng với dữ liệu huấn luyện nhằm đánh giá khả năng tổng quát hóa. Ảnh đầu vào được chuẩn hóa thành kích thước 480 khi được đưa vào mô hình để dự đoán vị trí và loại đối tượng. Kết quả đầu ra được biểu diễn dưới dạng hộp giới hạn (bounding box) kèm nhãn phân loại và độ tin cậy (confidence score). Với RetinaNet, dự đoán được tạo từ hai nhánh song song gồm classification subnet và box regression subnet của kiến trúc FPN, trong khi Deformable DETR sử dụng cơ chế cross-attention để kết hợp các truy vấn đối tượng (object queries) với đặc trưng ảnh, giúp xác định chính xác vùng chứa vật thể và giảm thiểu lỗi phát hiện. Hiệu quả của mô hình được đánh giá thông qua các chỉ số Precision, Recall, F1-score và Mean Average Precision (mAP). Kết quả thực nghiệm cho thấy Deformable DETR có khả năng nhận diện tốt hơn các vật thể nhỏ hoặc bị che khuất, trong khi RetinaNet cho tốc độ suy luận nhanh và kết quả ổn định hơn trên các lớp phổ biến. Cả hai mô hình đều chứng minh được hiệu quả của việc kết hợp cân bằng dữ liệu và tăng cường ảnh, góp phần nâng cao đáng kể độ chính xác phát hiện đối tượng giao thông trong điều kiện thực tế tại Việt Nam.

IV. KẾT QUẢ THỰC NGHIỆM

A. Môi trường cài đặt và tập dữ liệu thực nghiệm

1. Môi trường cài đặt

Phương pháp đề xuất được cài đặt trên nền tảng Kaggle GPU Tesla P100 với thư viện hỗ trợ cài đặt và đào tạo mô hình mạng sử dụng là PyTorch (v2.6.0), Albumentations (v2.0.8), OpenCV (v4.12.0) và NumPy (v1.26.4) với ngôn ngữ lập trình Python (v3.11.13).

2***. Tập dữ liệu thực nghiệm***

a. Dữ liệu đào tạo: Bộ dữ liệu sử dụng trong đề tài này được gộp từ bốn nguồn công khai (Intersection-Flow-5K, Object Detection of 35 Classes, Vietnamese Traffic Sign Detection Augmentation, và Road Issues Detection Dataset) với bộ dữ liệu mất cân bằng có 11 lớp, 24372 ảnh và 453982 đối tượng được gán nhãn, tỉ lệ giữa lớp nhiều đối tượng nhất với lớp ít đối tượng nhất là 327:1. Với bộ dữ liệu cân bằng có 11 lớp, 31849 và 81377 đối tượng được gán nhãn tỉ lệ giữa lớp nhiều đối tượng nhất với lớp ít đối tượng nhất là 15:1.

Bảng 1. Thông kế số lượng ảnh chưa cân bằng và mất cân bằng

STT	Lớp	Số lượng ảnh	
		Chưa cân bằng	Cân bằng

1	Vehicle	7493	1923
2	Bus	2929	5383
3	Bicycle	6234	1304
4	Person	5895	2288
5	Engine	1198	7863
6	Truck	4664	3895
7	Tricycle	1832	600
8	Obstacle	3555	850
9	Pothole	3947	886
10	Traffic Light	437	7758
11	Traffic Sign	10355	8382

b. Dữ liệu kiểm thử: Bộ dữ liệu kiểm thử được tách ra từ bộ dữ liệu đạo tạo với tỷ lệ 15% trên tổng số ảnh và bộ dữ liệu này hoàn toàn độc lập với bộ dữ liệu đào tạo với mất cân bằng là 3655 ảnh và cân bằng là 4766 ảnh.

B. Các kịch bản áp dụng

Để tiến hành thực nghiệm cho mô hình đề xuất, chúng tôi thực hiện 4 kịch bản với các tham số trong **Bảng 2**

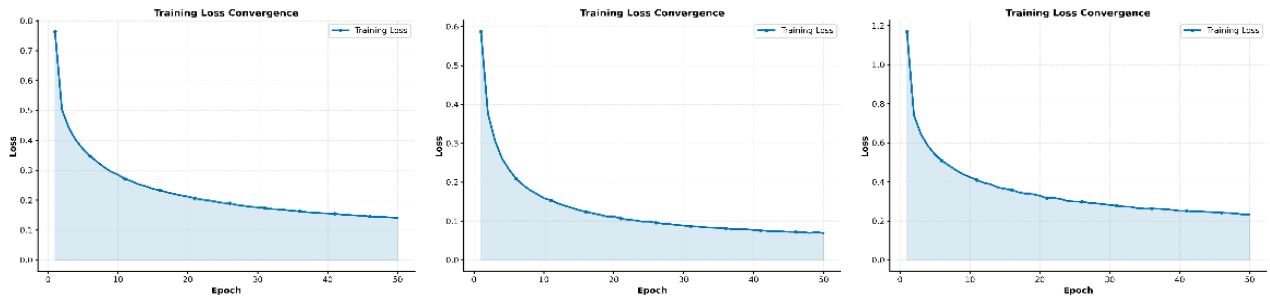
Bảng 2: Các kịch bản được đề xuất và các tham số huấn luyện

Kịch bản	Kiến trúc mạng	Backbone	Epoch	Learing rate	Image size
1	RetinaNet (Mất cân bằng)	ResNet-50	50	1e-4	432 x 432
2	RetinaNet (Cân bằng)	ResNet-50	50	1e-4	432 x 432
3	RetinaNet (Mất cân bằng)	MobileNetV3	50	3e-4	448 x 448
4	RetinaNet (Cân bằng)	MobileNetV3	80	3e-5 (50) 5e-5 (30)	448 x 448
5	Deformable DETR (Mất cân bằng)	ResNet-50	50	1e-4	480 x 480
6	Deformable DETR (Cân bằng)	ResNet-50	50	1e-4	480 x 480

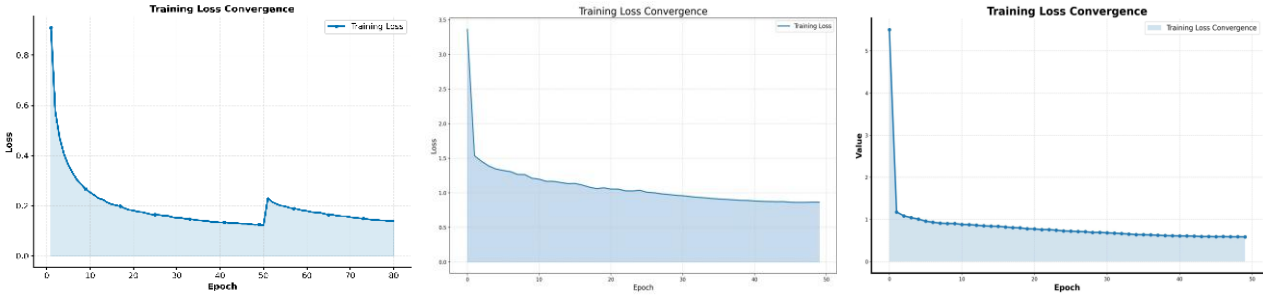
C. Kết quả huấn luyện.

1. Đánh giá mô hình

a. Độ đo Loss của các kịch bản



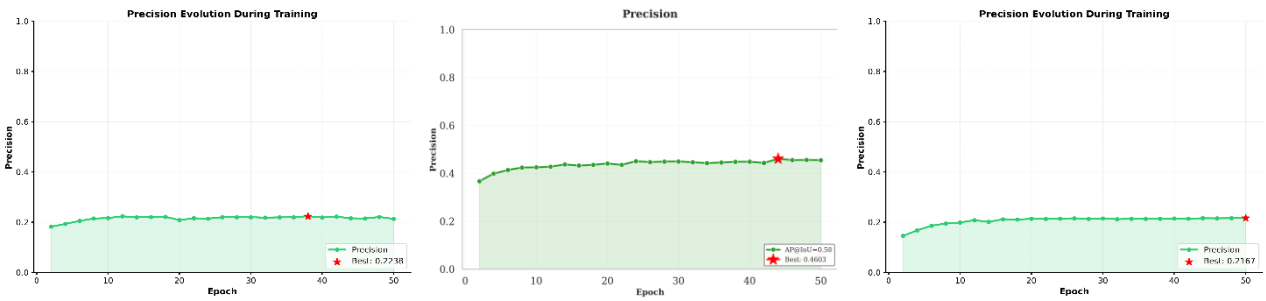
Kịch bản 1 Kịch bản 2 Kịch bản 3



Kịch bản 4 Kịch bản 5 Kịch bản 6

Hình 1: Độ đo Loss của các kịch bản trong giai đoạn huấn luyện

b. Độ đo Precision của các kịch bản

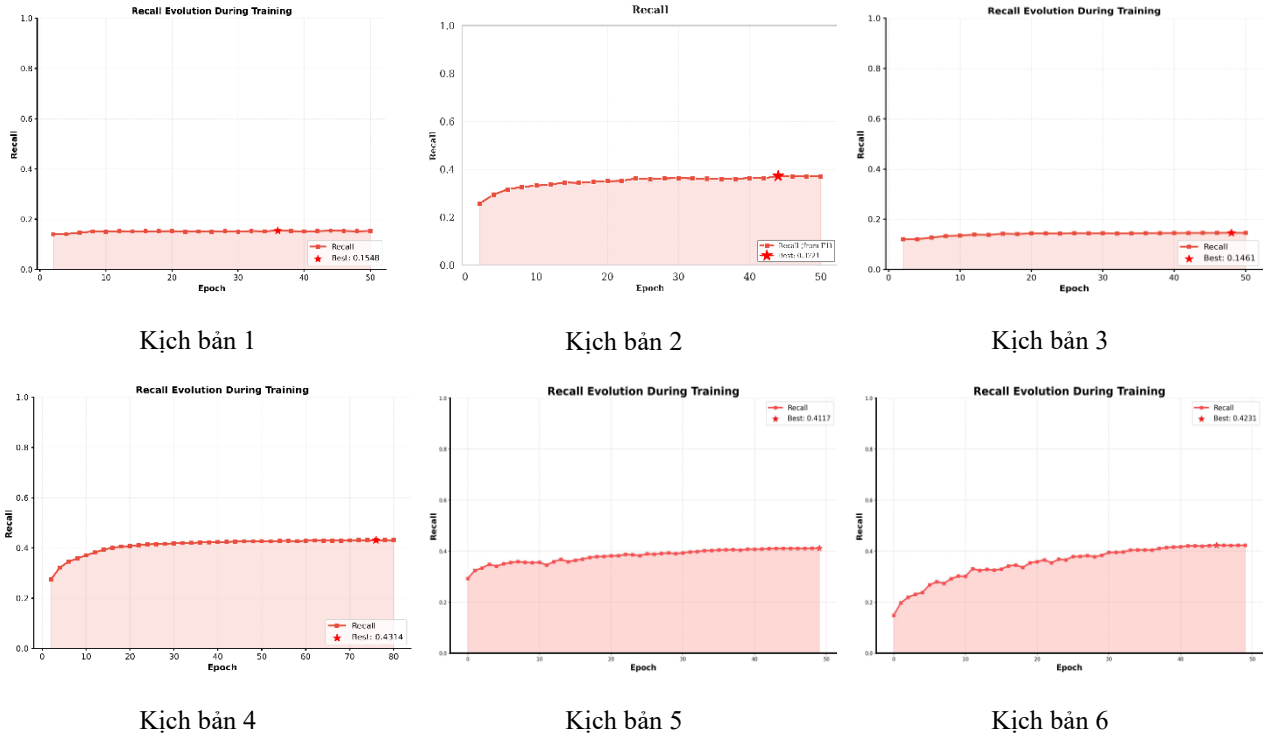


Kịch bản 1 Kịch bản 2 Kịch bản 3

Kịch bản 4 Kịch bản 5 Kịch bản 6

Hình 2: Độ đo Precision của các kịch bản trong giai đoạn huấn luyện

c. Độ đo Recall của các kịch bản

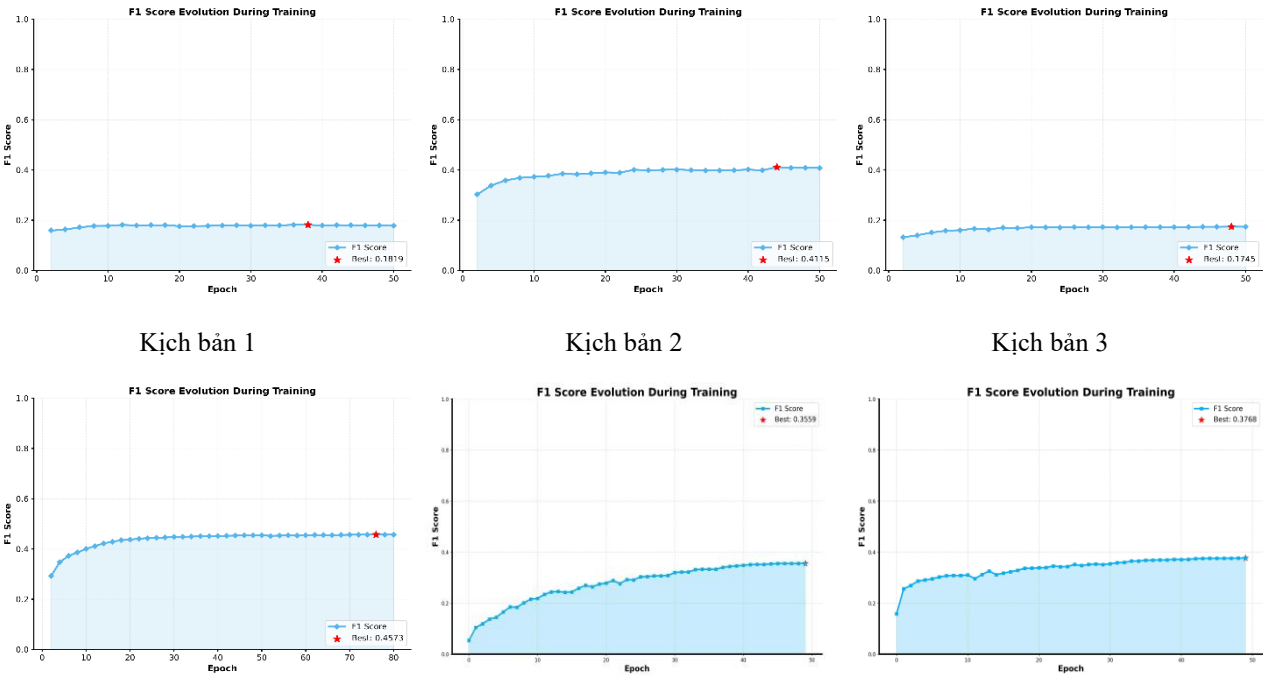


Kịch bản 1 Kịch bản 2 Kịch bản 3

Kịch bản 4 Kịch bản 5 Kịch bản 6

Hình 3: Độ đo Recal của các kịch bản trong giai đoạn huấn luyện

d. Độ đo F1-score của các kịch bản

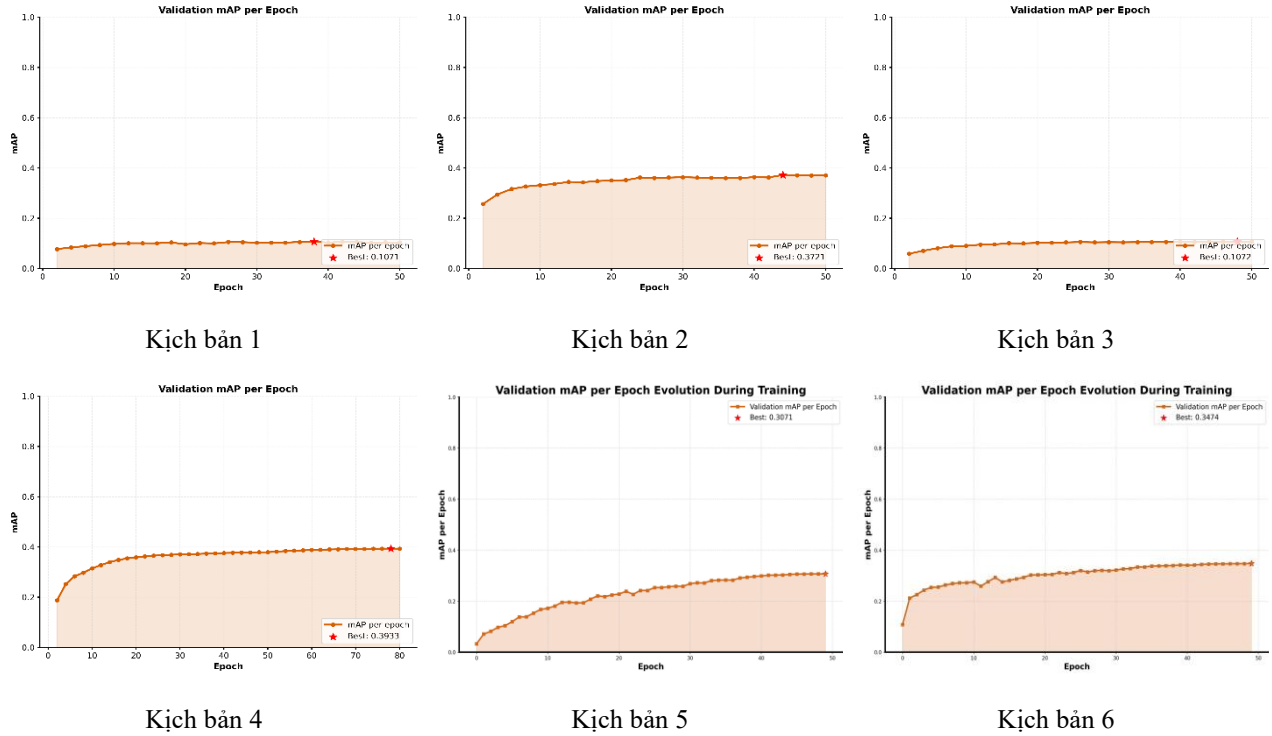


Kịch bản 1 Kịch bản 2 Kịch bản 3

Kịch bản 4 Kịch bản 5 Kịch bản 6

Hình 4: Độ đo F1-score của các kịch bản trong giai đoạn huấn luyện

e. Độ đo mAP của các kịch bản



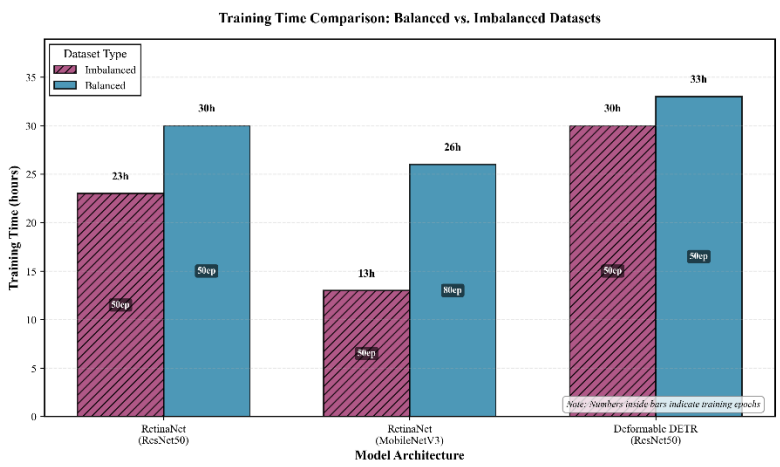
Kịch bản 1 | Kịch bản 2 | Kịch bản 3

Kịch bản 4 | Kịch bản 5 | Kịch bản 6

Hình 5: Độ đo mAP của các kịch bản trong giai đoạn huấn luyện

2. Thời gian huấn luyện

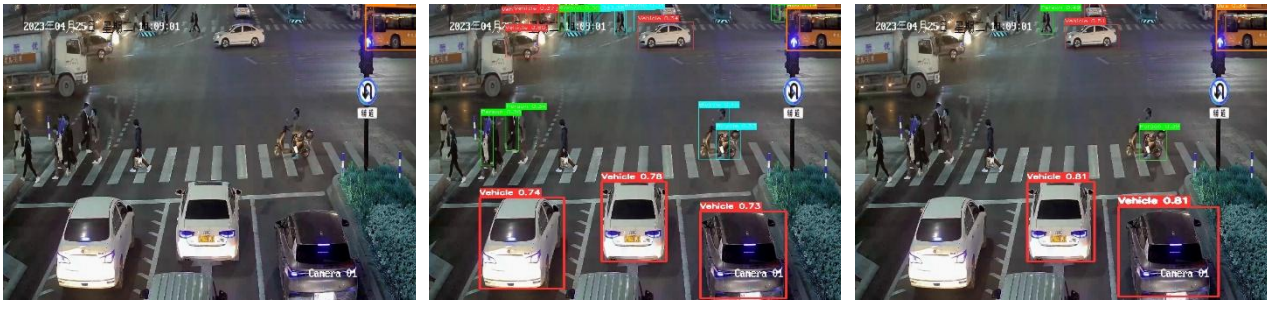
Hình 6 biểu diễn thời gian huấn luyện của các kịch bản đề xuất lần lượt là kịch bản 1 là 23 giờ, kịch bản 2 là 30 giờ, kịch bản 3 là 13 giờ, kịch bản 4 là 26 giờ, kịch bản 5 là 30 giờ và kịch bản 6 là 33h. Qua kết quả cho thấy sự đánh đổi rõ rệt giữa độ phức tạp của mô hình, khối lượng dữ liệu và thời gian huấn luyện: Về mô hình: RetinaNet-MobileNetV3 cho tốc độ huấn luyện nhanh nhất (chỉ 13h ở kịch bản 3), khẳng định tiềm năng ứng dụng cho các hệ thống nhúng hoặc thời gian thực. Ngược lại, Deformable DETR tiêu tốn nhiều tài nguyên tính toán nhất (lên tới 33h ở kịch bản 6) do độ phức tạp của kiến trúc Transformer, nhưng đổi lại thường mang lại khả năng phát hiện tốt hơn đối với các vật thể khó.



Hình 6. Thời gian huấn luyện của các kịch bản

D. Kết quả kiểm thử

1. Một số hình ảnh kết quả phân loại



Kịch bản 1 Kịch bản 2 Kịch bản 3



Kịch bản 4 Kịch bản 5 Kịch bản 6

Hình 7. Thời gian huấn luyện của các kịch bản

2. So sánh và thảo luận

Bảng 3: So sánh với các nguyên cứu liên quan

Tác giả	Phương pháp	Kết quả
Lin et al.[4]	RetinaNet + ResNet-101-FPN RetinaNet + ResNeXt-101-FPN	Dataset COCO test-dev mAP: 39.1 (ResNet-101-FPN) và 40.8 (ResNeXt-101-FPN)
Zhu et al.[5]	Deformable DETR + ResNet-50 Deformable DETR + ResNet-101 Deformable DETR + ResNeXt-101 Deformable DETR + ResNeXt-101 + DCN Deformable DETR + ResNeXt-101 + DCN	Dataset: COCO test-dev mAP: 46.9 (ResNet-50), 48.7 (ResNet-101), 49.0 (ResNeXt-101), 50.1 (ResNeXt-101 + DCN) và 52.3 (ResNeXt-101 + DCN)
Phương pháp đề xuất	RetinaNet + ResNet-50 RetinaNet + MobileNetV3	Dataset: Tập kiểm thử mAP: 36.52 (ResNet50) và 38.53 (MobileNetV3)
	Deformable DETR + ResNet-50	Dataset:Tập kiểm thử mAP: 34.74

V. KẾT LUẬN

Bài báo này đã giải quyết một trong những thách thức cốt lõi của các hệ thống giám sát giao thông thông minh: sự sụt giảm hiệu năng nhận dạng do mất cân bằng dữ liệu nghiêm trọng giữa các lớp đối tượng phổ biến (như xe cộ) và các lớp hiếm nhưng quan trọng (như ổ gà, biển báo, đèn giao thông). Chúng tôi đã đề xuất một quy trình toàn diện kết hợp giữa các kiến trúc phát hiện đối tượng tiên tiến (RetinaNet, Deformable DETR) và chiến lược cân bằng dữ liệu đa tầng bao gồm Adaptive Undersampling, Repeat-Factor Sampling và Mosaic Augmentation[18]. Kết quả thực nghiệm trên bộ dữ liệu tổng hợp gồm hơn 31.000 ảnh đã minh chứng tính hiệu quả của phương pháp đề xuất. Cụ thể: Về kỹ thuật xử lý dữ liệu: Việc giảm tỷ lệ mất cân bằng từ 327:1 xuống 15:1 đã cải thiện đáng kể độ chính xác (Precision) và độ nhạy (Recall) cho các lớp thiểu số, giúp mô hình không bị thiên lệch (bias) về phía các lớp đa số. Về hiệu năng mô hình: Deformable DETR thể hiện sự vượt trội trong việc phát hiện các đối tượng nhỏ, bị che khuất và có hình dạng phức tạp nhờ cơ chế Attention, trong khi RetinaNet (đặc biệt là phiên bản MobileNetV3) chứng minh được ưu thế về tốc độ huấn luyện và suy luận, phù hợp cho các bài toán yêu cầu thời gian thực. So sánh: Kết quả mAP đạt được (34.74% - 38.53 %) là cạnh tranh và tiệm cận với các nghiên cứu tiên tiến trên thế giới, khẳng định tính đúng đắn của việc kết hợp augmentation chuyên sâu với các mô hình hiện đại. Trong tương lai, chúng tôi dự định tối ưu hóa mô hình để triển khai trên các thiết bị biên (Edge Devices) có tài nguyên hạn chế và mở rộng nghiên cứu sang hướng học bán giám sát (Semi-supervised learning) để tận dụng nguồn dữ liệu video giao thông khổng lồ chưa được gán nhãn.

TÀI LIỆU THAM KHẢO

[1] Thanh Huyền, “Tai nạn giao thông cả nước năm 2023 tiếp tục được kiềm chế và kéo giảm so với năm 2022.” Accessed: Oct. 22, 2025. [Online]. Available: http://laocai.gov.vn/default.aspx?catname=an-toan-giao-thong&title=tai-nan-giao-thong-ca-nuoc-nam-2023-tiep-tuc-duoc-kiem-che-va-keo-giam-so-voi-nam-2022&id=1233538

[2] daibieunhandan.vn, “Gần 10.000 người chết vì tai nạn giao thông trong năm 2024,” Báo Đại biểu Nhân dân. Accessed: Oct. 22, 2025. [Online]. Available: https://daibieunhandan.vn/gan-10-000-nguoi-chet-vi-tai-nan-giao-thong-trong-nam-2024-10356034.html

[3] TTXVN B., “6 tháng đầu năm: Số vụ tai nạn giao thông giảm gần 25% so với cùng kỳ.” Accessed: Oct. 22, 2025. [Online]. Available: https://baocaovien.vn/tin-tuc/6-thang-dau-nam-so-vu-tai-nan-giao-thong-giam-gan-25-so-voi-cung-ky/240124.html

[4] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, “Focal Loss for Dense Object Detection”.

[5] X. Zhu, W. Su, L. Lu, B. Li, X. Wang, and J. Dai, “Deformable DETR: Deformable Transformers for End-to-End Object Detection,” Mar. 18, 2021, *arXiv*: arXiv:2010.04159. doi: 10.48550/arXiv.2010.04159.

[6] J. Pang, K. Chen, J. Shi, H. Feng, W. Ouyang, and D. Lin, “Libra R-CNN: Towards Balanced Learning for Object Detection,” in *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Long Beach, CA, USA: IEEE, June 2019, pp. 821–830. doi: 10.1109/CVPR.2019.00091.

[7] K. Oksuz, B. C. Cam, S. Kalkan, and E. Akbas, “Imbalance Problems in Object Detection: A Review,” Mar. 11, 2020, *arXiv*: arXiv:1909.00169. doi: 10.48550/arXiv.1909.00169.

[8] S. Yun, D. Han, S. Chun, S. J. Oh, Y. Yoo, and J. Choe, “CutMix: Regularization Strategy to Train Strong Classifiers With Localizable Features,” in *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, Seoul, Korea (South): IEEE, Oct. 2019, pp. 6022–6031. doi: 10.1109/ICCV.2019.00612.

[9] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, “YOLOv4: Optimal Speed and Accuracy of Object Detection,” Apr. 23, 2020, *arXiv*: arXiv:2004.10934. doi: 10.48550/arXiv.2004.10934.

[10] J. Fernández, J. M. Cañas, V. Fernández, and S. Paniego, “Robust Real-Time Traffic Surveillance with Deep Learning,” *Comput. Intell. Neurosci.*, vol. 2021, p. 4632353, Dec. 2021, doi: 10.1155/2021/4632353.

[11] S. Liu, T. Cai, X. Tang, Y. Zhang, and C. Wang, “Visual Recognition of Traffic Signs in Natural Scenes Based on Improved RetinaNet,” *Entropy*, vol. 24, no. 1, p. 112, Jan. 2022, doi: 10.3390/e24010112.

[12] L. Wen *et al.*, “UA-DETRAC: A New Benchmark and Protocol for Multi-Object Detection and Tracking,” Jan. 24, 2020, *arXiv*: arXiv:1511.04136. doi: 10.48550/arXiv.1511.04136.

[13] Y. Fang *et al.*, “You Only Look at One Sequence: Rethinking Transformer in Vision through Object Detection,” Oct. 27, 2021, *arXiv*: arXiv:2106.00666. doi: 10.48550/arXiv.2106.00666.

[14] C. Goutte and E. Gaussier, “A Probabilistic Interpretation of Precision, Recall and F-Score, with Implication for Evaluation,” in *Advances in Information Retrieval*, D. E. Losada and J. M. Fernández-Luna, Eds., Berlin, Heidelberg: Springer, 2005, pp. 345–359. doi: 10.1007/978-3-540-31865-1_25.

[15] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The Pascal Visual Object Classes (VOC) Challenge,” *Int. J. Comput. Vis.*, vol. 88, no. 2, pp. 303–338, June 2010, doi: 10.1007/s11263-009-0275-4.

[16] R. Padilla, S. L. Netto, and E. A. B. da Silva, “A Survey on Performance Metrics for Object-Detection Algorithms,” in *2020 International Conference on Systems, Signals and Image Processing (IWSSIP)*, July 2020, pp. 237–242. doi: 10.1109/IWSSIP48289.2020.9145130.

[17] B. Yaman, T. Mahmud, and C.-H. Liu, “Instance-Aware Repeat Factor Sampling for Long-Tailed Object Detection,” May 14, 2023, *arXiv*: arXiv:2305.08069. doi: 10.48550/arXiv.2305.08069.

[18] H. Zhang, S. Zhang, and R. Zou, “Select-Mosaic: Data Augmentation Method for Dense Small Object Scenes,” arXiv.org. Accessed: Dec. 08, 2025. [Online]. Available: https://arxiv.org/abs/2406.05412v1